Study: bảng tổng hợp tài liệu

RL cho VLA tổng quát; diffusion và flow matching trong sinh hành động

Mỗi ô ghi vị trí trong bài gốc (§, Eq., Table, App.). Số liệu là số tác giả báo cáo, chưa tái lập trong repo này, trừ các số SmolVLA ghi nguồn *probe*. Bảng 1 so sánh năm bài RL cho VLA; Bảng 2 so sánh diffusion và flow matching.

1. Năm phương pháp RL cho VLA

Bảng 1: Ma trận so sánh năm bài RL cho VLA.

Bài	Model nền, dạng action	Mục tiêu học	Reward	Cách huấn luyện, phần được update	Giả định	Kết quả chính	Câu hỏi còn mở
SimpleVLA-RL arXiv:2509.09674 (ICLR 2026)	OpenVLA-OFT 7B, head sửa thành token (256 token, chunk 8 trên LIBERO) (§4.1); **token**	GRPO, không critic, bỏ KL; clip [0,8; 1,28]; bỏ nhóm toàn thắng/toàn thua; nhiệt độ rollout 1,6 (§3.3–3.4, Eq. 10–11)	nhị phân 0/1 theo kết quả, gán cho mọi token của trajectory (§3.2, Eq. 9)	online, sim (LIBERO, RoboTwin); SFT trước rồi RL; 8×A800; update toàn bộ (§4.1)	SFT phải có success > 0 (SFT 0 traj. ⇒ RL vẫn 0%, §6.2); reset được môi trường	LIBERO TB 91,0→99,1, SFT đầy đủ (Table 2); SFT 1 traj./task: 48,9→96,9, Long 17,3→91,7 (Table 5)	học khi success ≈ 0 (§6.2); policy học đường tắt khác demo, đẩy vật thay vì gắp, "pushcut" (§6.1)
$\pi_{\mathbf{RL}}$ arXiv:2510.25889	π_0, $\pi_{0.5}$, 3,3B (App. B.2); **flow**	PPO + GAE ở mức chunk; log-likelihood qua Flow-Noise (§4.1) hoặc Flow-SDE (§4.2)	nhị phân trên LIBERO (App. C.1); ManiSkill thêm 0,1 khi gripper chạm vật (App. C.2)	online, sim, khung RLinf; SFT few-shot trước; 8×H100; chỉ update action expert ∼300M, VLM đóng băng (App. B.2)	có SFT trước; sim đủ nhanh để rollout online	LIBERO few-shot π_0: 57,6→97,6 (Flow-Noise) / 96,1 (Flow-SDE); $\pi_{0.5}$: 77,1→98,3 / 97,9 (Table 3)	cần nhiều rollout và reset (§6); Flow-Noise hay Flow-SDE tốt hơn tuỳ model (Table 1); MetaWorld OOD không cải thiện (§5.2.2)
$\pi^*_{0.6}$ **/ RECAP** arXiv:2511.14759	$\pi_{0.6}$: Gemma 3 4B + action expert 860M (§V-A); **flow** (+ token FAST phụ)	advantage conditioning: $-\log\pi(a \mid o,\ell) - \alpha\log\pi(a \mid I,o,\ell)$, $I = \mathbb{1}(A > \epsilon_\ell)$ (§IV-B, Eq. 3); value phân phối 201 bin, VLM 670M (Eq. 1, §V-C); không cần log-prob chính xác	-1 mỗi bước, 0 nếu thành công, $-C_{\text{fail}}$ nếu thất bại (Eq. 5)	lặp offline trên robot thật: thu rollout + can thiệp của người, huấn luyện lại từ checkpoint pretrain (Alg. 1, §V-D); update toàn bộ VLA + value function	quan sát Markov; can thiệp của người luôn tốt (I = True) (§IV-B); có người gán reward, can thiệp, reset (§VII)	robot thật: throughput tăng hơn 2 lần, tỉ lệ thất bại giảm khoảng một nửa ở task khó (abstract, Fig. 7); success > 90% trừ task giặt đồ đa dạng (Fig. 8)	phụ thuộc người reset, gán reward, can thiệp (§VII)
RIPT-VLA arXiv:2505.17016	QueST ∼20M (token); OpenVLA-OFT 7B (hồi quy liên tục) (§5.1); **token / liên tục**	PPO clip + advantage leave-one-out (RLOO), $K = 16$ (QueST) / 8 (OFT); bỏ context toàn thắng/toàn thua (Eq. 5–6, §4.2)	nhị phân 0/1, không critic (§3.1)	online, sim (LIBERO, MetaWorld ML45); OFT cần thêm head dự đoán scale Laplace để có log-prob (§4.3); OFT: LoRA $r = 32$ + action head (§5.1)	SFT có success > 0; reset được đúng context ban đầu cho cả nhóm rollout (§4.1–4.2)	LIBERO, QueST: 82,7→93,6, Long 68,8→87,5; OFT: 96,7→97,5 (Table 1); 1 demo: 3,5%→97,2% (§5.4)	học khi success ≈ 0 (§4.1); trần hiệu năng: SFT đã mạnh thì RL tăng ít (OFT +0,8, Table 1)
VLA-RL arXiv:2505.18719	OpenVLA-7B (§3); **token**	PPO + GAE, có critic, critic warmup (§3.3, §3.5); log-prob = tổng log-prob của 7 token action (Eq. 1)	sparse của môi trường + reward model quá trình (RPRM) học từ nhãn giả: tách bước con theo độ mở gripper và vận tốc ≈ 0 (§3.4)	online, sim (LIBERO 4 suite, mỗi suite train riêng); ∼48 GPU-giờ; LoRA	nhãn giả từ gripper/vận tốc khớp ranh giới bước con	LIBERO TB 76,5→81,0, Long 53,7→59,8 (Table 1)	RPRM dựa trên heuristic, tác giả thừa nhận khó áp dụng cho thao tác khéo léo (§5)

Câu hỏi còn mở chung (tổng hợp của em từ cột cuối):

1. **Reward thưa.** Reward nhị phân không cho gradient khi không rollout nào thành công (SimpleVLA-RL, RIPT-VLA); reward quá trình (VLA-RL) lại dựa trên heuristic.
2. **Hiệu quả mẫu và reset.** RL online cần nhiều rollout và reset về cùng cảnh ban đầu; trên robot thật phải cần người ($\pi^*_{0.6}$).

3. **Log-likelihood cho policy flow.** Chưa có cách tốt nhất cho mọi model (π_{RL}: Flow-Noise hay Flow-SDE tuỳ model); RECAP tránh hẳn log-prob.
4. **Tổng quát hoá và trần hiệu năng.** Kết quả OOD không ổn định; policy có thể học đường tắt; SFT càng mạnh thì RL tăng càng ít.

2. Diffusion và flow matching trong sinh hành động

Bảng 2: Ma trận so sánh diffusion (Diffusion Policy, DDPM) và flow matching (π_0, SmolVLA).

Tiêu chí	Diffusion (DDPM) — Diffusion Policy, arXiv:2303.04137	Flow matching — π_0 arXiv:2410.24164; SmolVLA arXiv:2506.01844
Điểm chung	Một mạng nhận *chunk action đang bị nhiễu* cùng bước thời gian/mức nhiễu, có điều kiện là quan sát, và trả ra một đại lượng (nhiễu hoặc vận tốc) để khử nhiễu dần từ Gauss về action.	
Kiến trúc	Điều kiện là quan sát O_t. Hai backbone (§3.1): CNN 1D với FiLM theo O_t và bước k; hoặc transformer, token action nhiễu đi qua cross-attention với embedding quan sát.	VLM xử lý ảnh, câu lệnh và state (prefix). *Action expert* là transformer nhỏ xử lý token action và attend vào đặc trưng VLM; KV của prefix được cache nên mỗi bước tích phân chỉ tính lại phần action (π_0 §IV, App. A-D). SmolVLA (probe): VLM SmolVLM2-500M (16 lớp ngôn ngữ, vision 12 lớp); tổng 450,0M tham số, action expert 98,2M (16 lớp, rộng 0,75 lần VLM); prefix 177 token (2 camera × 64 + 48 ngôn ngữ + state); output chunk 50×7; expert cross-attention vào VLM, xen self-attention mỗi 2 lớp.
Mục tiêu huấn luyện	Lấy action sạch x^0, chọn bước k, cộng nhiễu ε^k; mạng *dự đoán nhiễu*: $\mathcal{L} = \text{MSE}(\varepsilon^k,\ \varepsilon_\theta(O_t,\ x^0 + \varepsilon^k,\ k))$ (§2.2 Eq. 3, điều kiện O_t theo §2.3).	Nội suy thẳng giữa action và nhiễu; theo quy ước code SmolVLA $x_t = t\varepsilon + (1-t)A$, $t = 1$ là nhiễu thuần (probe; bài π_0/SmolVLA viết τ ngược chiều: $A^\tau = \tau A + (1-\tau)\varepsilon$). Mạng *dự đoán vận tốc*: $\|v_\theta(x_t, o) - (\varepsilon - A)\|^2$ (SmolVLA §3.1; Lipman và cộng sự, arXiv:2210.02747). t lấy theo phân phối Beta, ưu tiên mức nhiễu cao (π_0 App. A-B: Beta$((s-\tau)/s;\ 1{,}5,\ 1)$, $s = 0{,}999$).
Inference	Từ nhiễu Gauss x^K, lặp K bước $x^{k-1} = \alpha\big(x^k - \gamma\,\varepsilon_\theta(x^k, k) + \mathcal{N}(0, \sigma^2 I)\big)$ (Eq. 1); α, γ, σ theo noise schedule. Train 100 bước; inference DDIM 10 bước, 0,1 s trên RTX 3080 (§3.4).	Lấy nhiễu một lần, tích phân ODE bằng Euler từ $t = 1$ về 0: $x \leftarrow x - \Delta t\, v_\theta$. π_0 và SmolVLA dùng 10 bước (π_0 §IV, $\delta = 0{,}1$; probe `num_steps = 10`). SmolVLA: 96,5 ms/chunk (batch 1, RTX 5070 Ti; probe).
Đường từ nhiễu đến action	theo noise schedule α, γ, σ	đường thẳng (nội suy tuyến tính)
Tính ngẫu nhiên khi sinh	ở mọi bước (DDPM cộng nhiễu mỗi bước)	chỉ ở nhiễu ban đầu; phần còn lại tất định (ODE)
Log-likelihood của action	mỗi bước DDPM là một chuyển Gauss, nên log-prob của cả chuỗi khử nhiễu tính được	ODE tất định: log-likelihood chính xác phải tích phân divergence của v_θ dọc đường đi (như continuous normalizing flow), rất tốn; loss flow chỉ là cận dưới ($\pi^*_{0.6}$ Eq. 4)
Hệ quả cho RL	policy gradient (PPO, GRPO) dùng trực tiếp log-prob theo từng bước khử nhiễu	cần một trong các hướng: (1) chèn nhiễu học được vào mỗi bước Euler, mỗi bước thành Gauss (π_{RL} Flow-Noise §4.1); (2) đổi ODE thành SDE giữ nguyên phân phối biên, thành MDP hai tầng (π_{RL} Flow-SDE §4.2, Eq. 6–9); (3) bỏ log-prob, điều kiện policy theo advantage (RECAP Eq. 3); (4) xấp xỉ tỉ lệ likelihood bằng chênh lệch loss flow matching (FPO, arXiv:2507.21053; hướng dùng trong `main.tex`). SmolVLA cùng cấu trúc với π_0 nên (1), (2) áp dụng được bằng cách thêm nhiễu vào vòng Euler và thêm critic.

[Cần bạn điền / kiểm tra] Kiểm tra lại các số và vị trí trích từ bài báo trong Bảng 1 và 2; tên tác giả, năm, venue (ba bài SimpleVLA-RL, RIPT-VLA, VLA-RL chưa ghi tác giả).

Tài liệu tham khảo

- SimpleVLA-RL (2025). arXiv:2509.09674. (ICLR 2026, theo `git show e852bb7:docs/DAY1.md` mục D.)
- Chen và cộng sự (2025). π_{RL}: Online RL fine-tuning for flow-based VLA. arXiv:2510.25889.
- Physical Intelligence (2025). $\pi^*_{0.6}$ / RECAP. arXiv:2511.14759.
- RIPT-VLA (2025). arXiv:2505.17016.
- VLA-RL (2025). arXiv:2505.18719.
- Chi và cộng sự (2023). Diffusion Policy. arXiv:2303.04137.
- Black và cộng sự (2024). π_0. arXiv:2410.24164.
- Shukor và cộng sự (2025). SmolVLA. arXiv:2506.01844.

- Lipman và cộng sự (2022). Flow Matching for Generative Modeling. arXiv:2210.02747.
- McAllister và cộng sự (2025). Flow Matching Policy Gradients (FPO). arXiv:2507.21053.